

빅데이터 분석을 통한 축구 행동별 성공률 예측 모델링

Predictive Modeling of Soccer Action Success Rates Using Data Analysis

황성백
Hwang, Seong Baek

요 약

이 프로젝트는 2017/18년도 유럽프로축구리그의 남자 축구 선수들을 대상으로 강화학습의 대표적인 모델들을 활용하여 행동별 성공률을 예측하는 모델을 개발하는 것이다..이 목적을 달성하기 위해서 Wyscout 데이터베이스에서 제공하는 경기 데이터를 사용하였다. 총 2,462,726개의 경기 중 발생하는 모든 행동과 좌표를 포함하는 데이터를 사용하였다. 이 프로젝트의 주요 목적인 행동별 성공률 예측 모델링을 위해 여러 경기 데이터 중 공간좌표, 행동들과 같은 독립 변수를 추출하여 성공 결과를 기준으로 이진 분류 모델을 사용하여 모델링을 진행했다. 축구데이터는 행동들이 일어나는 좌표들의 분포가 각자 다른 것들을 확인했다. 그중에서 분포가 특정 구역에 위치에서 성공할 확률이 상이한 것을 확인할 수 있었다. 성공확률도 분포에 따라 비슷하게 나타났지만, 크로스과 같은 행동은 자주 시도하는 위치와 다르게 가운데 박스 밖 위치에서 성공률이 높게 측정되었다. 이 프로젝트는 축구에서 데이터 분석이 단순히 팀 단위 전술과 승리 확률예측에 주로 사용되었다면 개인의 행동별 성공률을 분석함으로 선수별 분석과 새로운 평가지표를 제공할 수 있음을 보여준다. 이 프로젝트를 통해 축구에서 데이터 분석의 필요성과 효과성을 강조하며 행동별 성공률 예측 모델이 축구 전략 및 선수 퍼포먼스 향상에 실질적인 기여할 수 있음을 보여준다.

주제어: 축구, 행동, VAEP, 이진 분류, 평가지표

1. 서론

1.1 연구 배경 및 필요성


현대 축구는 단순한 스포츠를 넘어 축구 산업으로 성장하며 막대한 경제적 가치를 창출하고 있다. 유럽 축구리그 내 각 팀들은 기업들이 팀과 파트너십을 통해 거대한 자본을 바탕으로 선수 영입과 전략적 투자에 큰 우위를 선점하고 있다. 이를 바탕으로 축구 시장규모는 더욱 확장되게 되었지만, 리

그 내 팀별 경제적 양극화는 심화되고 있으며 리그 내 경쟁 불균형을 초래하게 되었다. 이는 경기력뿐만 아니라 장기적인 리그 경쟁 구도에도 영향을 미치고 있다.


이러한 양극화 속에서도 제한된 자원을 효율적으로 활용하여 성과를 낸 사례가 있다. 2021/22시즌 개막전에서 브렌트포드가 아스날을 승리한 사례는 단순한 이변으로 여겨졌지만, 이후에도 상위권 팀과의 경기에서 좋은 경기력을 선보인 결과 국내외 많은 축구 관계자들에게 관심을 받게 되었다.

이는 데이터 분석을 통해 선수의 역량을 평가하고, 제한된 자원으로 최적의 전략을 수립한 것으로 평가되었다. 이처럼 빅데이터와 인공지능 기술의 발전은 축구 경기력에 직접적인 영향을 미칠 수 있음을 보여주며 그 필요성을 시사하고 있다.[1]

상위권 클럽들은 이러한 사례를 바탕으로 데이터 분석의 중요성을 인식하고 구단 운영과 전략에 도입하고 있다. 상위권 팀 (예를 들어 맨체스터 유나이티드, 리버풀, 첼시 등)은 전문 데이터 분석관을 고용하여 선수를 영입하고 감독에게 전략적 선택지를, 구단에게는 장기적인 리그 운영계획을 제공한다.



<그림 1> EPL transfer spending
(기간: 2003/04 to 2022/23)



<그림 2> EPL Purchase total per club

1.1 기존 연구 및 한계점

축구에서 데이터 분석은 대부분 팀 단위의 결과나 선수의 전체적인 퍼포먼스를 평가하는 데 초점을 맞추고 있지만, 경기 내에서 발생하는 개별 행동의 성공 가능성을 수치적으로 예측하고 이를 기반으로 한 전략 수립은 미비한 상황이다.

특정 지역에서의 패스 성공률, 골대와의 거리와 각도에 따른 슈트 성공률 등 세부적인 행동 데이터를 활용한 분석은 효과적인 전략 수립과 선수 훈련 계획에 있어 중요하지만, 이러한 세밀한 행동 기반 예측은 축구 산업 내에서 사용되고 있지 않으며, 기존 연구에서도 공간적 맥락과 행동의 상황적 중요성에 대한 필요성이 충분히 제기되지 못한 상황이다.

1.3 연구 목적 및 기여

해당 프로젝트의 목적은 축구 경기에서 발생하는 행동 데이터를 기반으로 행동별 성공률을 정량적으로 예측하는 모델을 개발하는 알고리즘을 찾고 분석하는 데 있다. 특히 공간좌표 데이터, 개별 행동 데이터, VAEP(Valuing Actions by Estimating Probabilities)를 활용해 분석함으로써 구체적인 행동 성공률을 공간좌표 기준으로 예측하고자 하였으며 클럽이 이것을 통해 심층적으로 분석할 수 있도록 돕고자 한다. 선수 행동과 공간좌표와 같은 미시적인 정보가 경기에 영향을 미치며 전략 수립에 직접적인 영향이 있고, 데이터 분석이 도입되고 있는 축구 산업이 나아가야 할 방향성을 제시하고자 한다.

2 이론적 배경

2.1 축구 데이터 분석 개요

VAEP(Valuing Actions by Estimating Probabilities)

$$V(a_i, x) = \Delta P_{scores}(a_i, x) + (-\Delta P_{concedes}(a_i, x))$$

축구 경기의 데이터 분석에서 VAEP(Valuing Actions by Estimating Probabilities)는 각 행동을 수치적으로 평가하는데 재기된 지표이다. 기존에는 득점과 어시스트와 같은 직 결과 중심의 지표에 집중되었다면, VAEP가 등장한 이후 행동에 가치를 할당하는 혁신적인 방법론을 제시하였다. [2]

VAEP는 각 행동이 팀의 득점 확률을 높이는지, 실점 확률을 낮추는지에 따른 행동의 가치를 부여한다. 다양한 행동(패스, 크로스, 드리블 등)을 단순히 성공 여부를 판단하는 것을 넘어서 골과 실점에 어느 정도 영향을 미쳤는지 수치적으로 가치를 매길 수 있다. 이것은 선수와 팀의 기여도를 보다 심층적으로 평가할 수 있다. 이 프로젝트에서는 VAEP를 하나의 독립변수로 활용하여 행동별 성공률을 예측하고, 이 성공률을 바탕으로 예측모델의 활용도에 대한 근거를 강력히 제시한다.

축구 관련 용어

축구는 피치(Pitch)라는 경기장 안에서 11명씩 한 팀을 이루어 두 팀이 경기장 양 끝에 놓인 상대팀 진영 골대 안으로 공을 넣으면 득점을 하는 스포츠이다. 또한 들어간 득점수를 기준으로 상대방보다 높다면 승리, 같으면 무승부, 낮다면 패배로 간주한다. [3]


피치의 규격은 터치라인의 길이 90~120 미터, 골라인의 길이 45~90 미터로 유동적이다. 새롭게 지어지는 경기장의 터치라인과 골라인 길이를 각각 105미터, 68미터로 통일하기로 결정되었다.

축구는 주로 패스(Pass)와 드리블(Dribble)로 공을 소유한 상태를 유지하며 상대방 골대 근처로 이동하여 슈트(Shot)를 하여 골을 넣는다. 슈트를 통해 골을 넣었다면 공을 주기 전, 마지막 패스를 어시스트라고 한다. 터치라인 부근에서 상대팀 진영 골대에 가까운 쪽으로 같은 팀 선수에게 공을 길게 띄워서 가로질러 패스를 해주는 것을 크로스(Cross)라고 한다. 패스를 중간에 가로채는 것을 인터셉션(Interception)이라 하며, 태클(Tackle)은 상대팀의 공을 빼앗거나 패스, 드리블을 차단할 때 넘어지면서 저지하는 수비 기술이다. 클리어런스(Clearance)는 공을 자신의 진영의 골문 가까이 있는 공을 반대쪽으로 멀리 차거나 내보내 실점의 위험을 막는 것이다. 파울(Foul)은 축구 내 발생하는 비신사적 행위를 심판이 자율적으로 판단해 지적하는 것이고, 파울이 선언되면 파울을 한 선수의 상대팀에게 프리킥(Freekick)이 주어진다.

다.[4]

2.2 머신러닝 및 강화학습

지도 학습(Supervised Learning)은 입력과 출력의 쌍을 기반으로 입력을 출력에 매핑하는 함수를 학습하는 머신러닝 작업을 말한다. 지도 학습은 레이블이 있는 학습 데이터로부터 함수를 유추한다. 지도 학습 알고리즘은 외부의 도움이 필요한 알고리즘을 의미한다. 입력 데이터셋은 학습 데이터(train dataset)와 테스트 데이터(test dataset)로 나뉘어진다. 대부분의 강화학습 알고리즘은 <그림3>을 따른다. [5]



<그림 3> Supervised Learning Workflow

대표적인 앙상블 모델(Ensemble Models)

앙상블 학습은 주로 두 가지 기법인 배깅(bagging; bootstrap aggregating)과 부스팅(boosting)을 사용하여 모델을 결합한다. 배깅은 주어진 데이터에 대해서 여러 개의 부트스트랩(bootstrap) 자료를 생성하고 각 부트스트랩 자료를 모델링한 후 결합하여 최종의 예측 모델을 산출하는 방법이다. 배깅은 분류와 회귀 문제 모두에 사용할 수 있으며, 분산을 감소시키고 과적합을 처리하는데 도움을 준다. 배깅의 대표적인 모델로는 랜덤 포레스트가 존재한다. 부스팅은 잘못 분류된 개체들에 집중하여 새로운 분류규칙을 만드는 단계를 반복하는 방법이다. 즉, 약한 예측모형들을 결합하여 강한 예측모형을 만드는 것이 부스팅 알고리즘이다. 부스팅의 대표적인 모델로는 XGBoost, LightGBM이 존재한다. [5]

3. 연구방법

3.1 연구절차

이 프로젝트의 절차는 다음과 같다. 첫째, 선수의 개인별 행동 확률을 분석하기 위해 Wyscout에서 제공하는 경기 내 발생하는 이벤트를 포함하는 데이터를 수집하였다. 둘째, 수집한 데이터를 정제하는 과정을 통해 목적과 부합한 입력 변수를 필터링하였고 종속변수를 구분하여 이진 분류를 진행하고자 하였다. 셋째, 로지스틱 회귀, 랜덤 포레스트, XGBoost, LightGBM과 같은 대표적인 머신러닝 모델을 사용하여 확률을 예측하여 해당 프로젝트의 목표를 달성하기 위해 활용하였다. 넷째, 각종 평가지표를 통해 높은 정확도를 선보인 모델을 추려보았고 이 예측모델을 통해 실제 경기에서 사용될 수 있는 방안을 모색해보았다.

3.2 연구자료

이 프로젝트의 목적을 달성하기 위해 Wyscout에서 제공하는 축구 경기 데이터를 활용하여 분석하였다. Wyscout는 축구 분석 분야에서 가장 신뢰받는 데이터 제공자로, 유럽 프로리그에서 발생하는 모든 경기 이벤트를 상세히 기록한 데이터를 제공한다. Wyscout 데이터는 특히 시간과 공간 정보가 포함된 높은 데이터를 기반으로 하여 패스, 슈트, 테클, 크로스과 같은 이벤트를 정밀하게 기록하고 있다.

이 데이터는 La Liga, Serie A, Bundesliga, Premier League, Ligue 1, FIFA 월드컵 2018, 유로 2016 등 7개 주요 대회에서 한 시즌 동안 발생한 경기를 포함하고 있으며, 해당 리그 혹은 대회에서 발생한 모든 시공간적 이벤트를 다룬다. 데이터는 다음과 같은 정보를 포함한다.

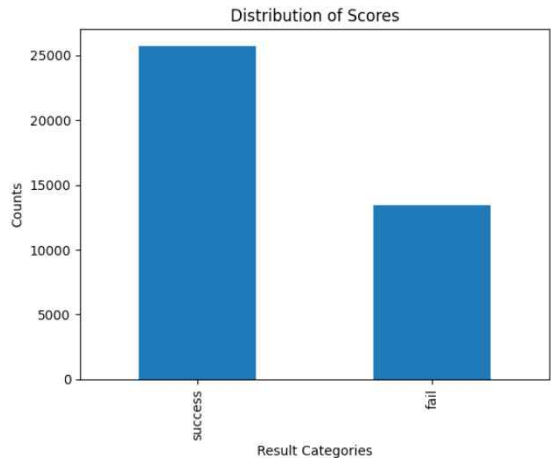
모델링에 포함된 입력 변수는 다음과 같다:

- type : 행동들 (크로스, 프리킥 크로스, 슈트, 테클)
- time_seconds : 행동이 일어난 시간
- start_x : 행동이 일어난 X좌표 (0~106)

- start_y : 행동이 일어난 Y좌표 (0~68)
- VAEP
- offensive_value
- deensive_value

분석에 필요한 데이터 중 type은 패스와 드리블 같은 경기 중 발생한 행동에 대한 정보를 포함하고 있으며, 해당 행동이 발생한 공간좌표, 행동의 성공 여부를 포함하고 있다. 데이터 전처리에는 다음과 같은 과정을 거쳐서 진행하였다.

- 결측값 처리: NULL값을 포함하는 데이터는 모두 제거하였다.
- 데이터 정규화: 공간좌표 (X,Y)는 규격이 서로 달라 표준화를 통해 모델 학습 시 스케일 차이를 제거하였다.
- 행동 필터링: 모든 행동 데이터를 학습에 사용하고 싶었지만 패스나 드리블의 경우 전 지역에서 대부분 성공하여 공간좌표의 특성을 제대로 활용하지 못하기에 필터링하였다. 그리고 극심한 데이터 불균형을 선보이기에 학습하는 데 있어서, 문제가 있어 5가지의 행동으로 필터링하여 사용하였다.



<그림 4> SMOTE전 데이터 분포

- SMOTE : 수집한 축구 경기 데이터는 행동 유형별 성공/실패 비율의 불균형이 존재했다. 이 데이터 불균형을 해결하기 위해 SMOTE라는 오버샘플링을 사용하였다. 오버샘플링을 통해 성공/실패

클래스 간 비율이 균형을 이루게 되어 예측 성능 개선할 수 있었다.

3.3 모델링 방법

이 프로젝트에서는 다양한 머신러닝 알고리즘을 활용하여 축구 경기 행동의 성공확률을 예측하였다. 사용된 모델은 다음과 같다:

- 로지스틱 회귀(Logistic Regression)
독립변수와 종속변수 집합 사이의 관계를 함수를 통해 예측하는 것이다. 종속변수는 주로 이산형이며, 유효한 클래스의 개수가 두 개인 경우에 사용된다. 종속 변수에 두 결과 0과 1만 있으면 이항형 로지스틱 회귀분석이라고 한다.
- 랜덤 포레스트(Random Forest): 배깅 기법을 활용하여 안정성과 변수 중요도 평가 기능을 제공한다.
- XGBoost(Extreme Gradient Boosting): Gradient Boosting 알고리즘을 개선하여 높은 예측 성능과 처리 속도를 제공한다.
- LightGBM(Light Gradient Boosting Machine): 대규모 데이터에서도 효율적으로 학습이 가능한 Gradient Boosting 기반의 경량화된 모델이다

3.4 성능 평가

이 프로젝트에서는 행동별 성공률 예측 모델의 성능을 평가하기 위해 다양한 지표를 활용하였다. 각각의 지표는 정확도, 정밀도, 재현율, F1 스코어, 브라이어 점수(Brier Score), ROC

분류한 데이터의 비율을 나타내는 지표이다.

정확도는 모델이 전체 데이터 중 올바르게 분류한 데이터의 비율을 나타내는 지표이다.

정밀도는 모델이 성공으로 예측한 데이터 중 실제로 성공인 데이터의 비율을 측정하는 것이다 재현율은 실제 성공 데이터를 모델이 성공으로 올바르게 예측한 비율을 나타낸다.

F1 스코어(F1 Score)는 정밀도와 재현율의 조화 평균으로, 이 프로젝트에서는 성공과 실패 비율이 다른 클래스 불균형 문제를 해결하기 위한 평가지표로 적합하다.

브라이어 점수(Brier Score) 브라이어 점수는 모델이 예측한 확률 값의 정확도를 평가하는 지표로, 이산형 확률 분포와 관찰된 결과 간의 평균 제곱 오차를 나타낸다

ROC 곡선(Receiver Operating Characteristic Curve)은 모델의 분류 경계값을 변화시키며 계산한 TPR(True Positive Rate)와 FPR(False Positive Rate)간의 관계를 시각화한 그래프이다. 곡선 아래 면적은 모델이 무작위 추측보다 얼마나 나은지를 측정하며, 다음과 같이 해석된다.

- AUC = 1.0: 완벽한 분류 성능
- AUC = 0.5: 무작위 추측 수준

ROC 곡선과 AUC는 모델의 전반적인 분류 성능을 요약하는 지표로, F1 스코어와 비슷하게 클래스 불균형 문제에 덜 민감하다.

4 결과 및 분석

Model	Accuracy	Precision	Recall	F1Score	BrierScore
LogisticRegression	0.878275	0.934952	0.874556	0.903746	0.088626
RandomForest	0.879308	0.919325	0.893718	0.906341	0.086724
XGBoost	0.8846	0.921351	0.900237	0.910671	0.083889
LightGBM	0.871176	0.898744	0.904781	0.901752	0.10516

표 1 각 모델에 대한 성능 평가 지표

곡선을 사용하였다.

정확도는 모델이 전체 데이터 중 올바르게

4.1 모델 성능 비교

로지스틱 회귀는 단순한 구조로 정밀도에서 가장 높은 성능을 보여주었다. 그러나 재현율이 상대적으로 낮아 일부 성공 데이터를 놓치는 경향이 있음을 확인하였다. F1 스코어와 브라이어 점수는 각각 0.9037, 0.0886로 전반적으로 균형 잡힌 성능을 보였으나 다른 모델과 비교했을 때는 다소 제한적인 성능을 보였다.

랜덤 포레스트는 정확도와 재현율에서 높은 성능을 기록하며 안정적인 성능을 보였다. 랜덤 포레스트는 또한 변수 중요도 평가 기능을 제공하며 이 프로젝트에서는 특정 행동의 성공확률에 중요한 영향을 미치는 변수들을 확인할 수 있다.

XGBoost는 모든 지표에서 최상의 성능을 기록하며, 이 프로젝트에서 가장 우수한 모델로 평가되었다. 정확도, 정밀도, 재현율, F1 스코어 모두 가장 높은값을 나타냈다. XGBoost는 데이터의 복잡한 상호작용을 효과적으로 모델링하며, 행동별 성공률 예측에서 가장 뛰어난 성능을 제공하였다.

LightGBM은 재현율에서 가장 높은값을 기록하며 성공 사례를 거의 놓치지 않았지만, 정밀도와 브라이어점수에서는 다른 모델보다 낮은 성능을 보여주었으며, 전반적인 F1 스코어는 0.9017로 가장 낮은값을 보여주었다.


모델 비교 결과, XGBoost가 가장 우수한 성능을 기록하며 이 프로젝트의 목적인 행동별 성공률 예측에 가장 적합한 모델임을 확인하였다. 하지만

나은 선택이 될 수 있으며, 사용 목적과 데이터의 특성에 따라 달라질 수도 있다. 이번 프로젝트에서는 XGBoost를 이용하여 본격적인 분석을 진행하려고 한다.

4.2 행동별 성공률 패턴 분석


예측모델을 통해 축구 경기 중 다양한 행동의 성공률을 분석하여 행동별로 발생 위치, 성공률의 분포, 그리고 해당 행동의 성공 여부를 통하여 골에 영향을 어느정도 미치는지 파악하였다. 시각화를 통해 특정 패턴과 특징을 식별하고 행동 성공률의 공간적 맥락을 구체화하였다.

슛

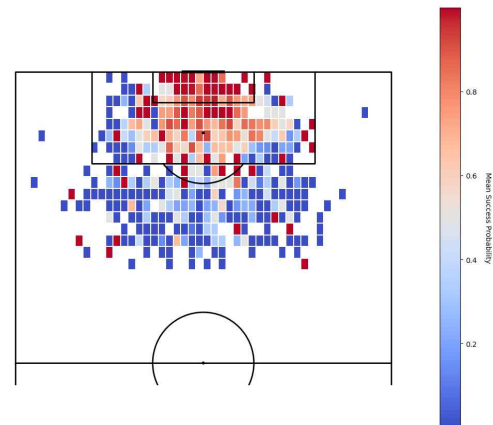


<그림 6> 슛 히트맵

Success Probability Heatmap for Shot





<그림 5> ROC Curve
특정 상황에서는 랜덤 포레스트나 LightGBM이 더



<그림 7> 슛 성공률 히트맵



슛은 주로 골대와 가까울수록 빈도수가 많았고 실제로 성공률도 높았다.

지역에서도 활발한 활동을 해야할 필요성을 보여 준다.



<그림 8> 선방 히트맵
Success Probability Heatmap for Keeper_save

<그림 10> 크로스 히트맵
Success Probability Heatmap for Cross



<그림 9> 선방 성공률 히트맵

<그림 11> 크로스 성공률 히트맵

선방

선방은 주로 골키퍼가 위치하는 페널티박스 안에서 많이 이루어지고 빈도수를 히트맵을 통해 그려하다는 사실을 알 수 있다. 하지만 성공률 히트맵을 보면 페널티 박스 이외에도 성공률이 높았던 지역이 있었고 이를 바탕으로, 현대 축구에서 중요시 여겨지는 스위퍼 키퍼에 대해서 다시 생각해볼 필요가 있다. 키퍼는 단순히 페널티박스 안에서의 선방을 통해 실점률을 낮추는 것이 아니라 이외의

크로스

크로스는 일반적으로 윙어(Winger)들이 흔히 라인을 따라 드리블 후 코너킥 위치 부근에서 길게 패스를 하곤 한다. 이것은 그림<10>의 히트맵을 통해 알 수 있다. 하지만 성공률 히트맵을 살펴보면 양쪽 터치라인 근처에서 성공률을 보이기보단 골대 쪽으로 가까이에서 크로스를 시도했을 때 더 높은 성공률을 보였다. 해당 데이터는 2017/18년

도 프로축구리그에서 발생한 행동 데이터로 인버티드 풀백이라는 용어가 등장하기 전의 시기인데 이것을 통하여 새로운 지평을 연 펍 과르디올라 감독의 인사이트를 데이터 분석을 통해서도 알 수 있었다.

4.3 공간좌표 기반 성공률의 의미

축구 경기에서 공간적 요소는 팀과 선수의 행동 성공률에 중요한 영향을 미친다. 해당 프로젝트에서는 모든 요인을 담지 못했지만, 행동 성공률은 일반적으로 경기 상황, 상대 팀의 수비 밀집도, 경기장 위치와 같은 다양한 요인에 따라 달라진다. 이 프로젝트에서는 특히 공간좌표를 활용하여 특정 지역에서의 행동 성공률을 수치적으로 분석하고 선수 및 전략에 반영할 수 있음을 보여준다.

5 결론

5.1 연구 요약

이 프로젝트에서는 축구 경기 데이터를 기반으로 프로축구 선수의 행동별 성공률을 예측하는 모델을 개발하였다. 주요 분석 대상으로는 VAEP와 같은 현대 축구데이터 분석 지표와 공간좌표와 주요 행동 데이터를 기반으로 한 머신러닝 모델을 통해 프로축구 선수의 행동별 성공률을 분석하여 시각적으로 심도 있게 분석할 수 있었고, 기존 전통적인 역할론에서 벗어나 개인의 선수가 특정 지역에서 어떤 전략적 선택을 해야 하는지에 대한 해결책을 제공한다.

5.2 향후 연구 방향

이 프로젝트를 통하여 축구에서 선수 개인의 행동별 성공률이라는 새로운 평가지표를 제시하였지만 사용된 데이터에 포함되는 정보는 지극히 제한적이다. 경기의 맥락과 선수 개인의 특성, 선수 개인의 멘탈 및 감정 등과 같은 성공률에 직접적인 영향을 미치지만 해당 데이터에는 포함되어 있지

않았다. 팀의 전략과 같은 전술적인 부분도 고려되어 있지 않아 향후 연구에서는 다음과 같은 방향으로 확장할 수 있다. 첫째, 추가 데이터를 통합하여 동일한 과정을 진행한다. 현재 사용된 데이터 외에 심박수, 운동량, 경기 맥락, 스코어와 같은 데이터를 통합하여 보다 정확한 선수 평가 모델을 개발할 수 있다. 둘째, 팀 전술의 최적화를 위한 행동분석 및 팀 전체의 성공 가능성을 평가하는 연구로 확장한다. 셋째, 선수를 영입할 때, 이 평가지표와 함께 선수의 몸값을 책정해보다 효율적이고 성공적인 영입 전략을 세울 수 있다.

참고문헌

- [1] Lewis, D., & Nabbi, Z. (2023, March 10). *Brentford FC: Premier League club sifts through over 85,000 players using data and 'good eyes'*. CNN. Retrieved from <https://edition.cnn.com/2023/03/10/football/brentford-moneyball-succe ss-premier-league-spt-intl/index.html>
- [2] T Decroos , L Bransen, JV Haaren ,J Davis (2019) Actions speak louder than goals: Valuing player actions in soccer. In: Proceedings of the 25th
- [3] Wikipedia, Association football, 2022, https://en.wikipedia.org/wiki/Association_football.
- [4] Wikipedia, Laws of the Game (association football), 2022, [https://en.wikipedia.org/wiki/Laws_of_the_Game_\(association_football\)](https://en.wikipedia.org/wiki/Laws_of_the_Game_(association_football))
- [5] Mahesh, Batta. "Machine learning algorithms-a review." International Journal of Science and Research (IJSR).[Internet] 9.1 (2020): 381-386.